

# Chapitre 4 : Estimation

## MA 361 : Probabilités continues

Pierre-Alain TOUPANCE  
pierre-alain.toupance@esisar.grenoble-inp.fr

Grenoble INP - ESISAR  
3<sup>ième</sup> année

12 décembre 2018

Le but de l'estimation consiste à partir d'un échantillon de prévoir des informations sur la population totale.

On effectue deux types d'estimations :

- estimation ponctuelle
- estimation par intervalle de confiance

Soit  $\Omega$  dont on considère un caractère :

On prend un échantillon de  $n$  individus et l'on obtient les données  $x_1, x_2, \dots, x_n$

On pose :

$$\hat{m} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

$$\hat{s}^2 = \frac{(x_1 - \hat{m})^2 + \dots + (x_n - \hat{m})^2}{n}$$

Soit  $X_1, X_2, \dots, X_n$  les variables aléatoires correspondant à ces données de moyenne  $m$  et de variance  $s^2$ , on pose :

$$\overline{X}_n = \frac{X_1 + \dots + X_n}{n}$$

$$S_n^2 = \frac{(X_1 - \overline{X}_n)^2 + \dots + (X_n - \overline{X}_n)^2}{n}$$

## Estimation ponctuelle

On a :

- $E[\bar{X}_n] = m$ ,  $\hat{m}$  est donc une estimation ponctuelle de  $E[X]$
- $E(S_n^2) = \frac{n-1}{n}s^2$ , ainsi  $\frac{n}{n-1}\hat{s}^2$  est une estimation ponctuelle de  $V(X)$

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n ((X_i - m) - (\bar{X}_n - m))^2$$

$$S_n^2 = \frac{1}{n} \left( \sum_{i=1}^n (X_i - m)^2 + \sum_{i=1}^n (\bar{X}_n - m)^2 - 2 \sum_{i=1}^n (X_i - m)(\bar{X}_n - m) \right)$$

$$S_n^2 = \frac{1}{n} \left( \sum_{i=1}^n (X_i - m)^2 + n(\bar{X}_n - m)^2 - 2(\bar{X}_n - m) \sum_{i=1}^n (X_i - m) \right)$$

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n ((X_i - m) - (\bar{X}_n - m))^2$$

$$S_n^2 = \frac{1}{n} \left( \sum_{i=1}^n (X_i - m)^2 + \sum_{i=1}^n (\bar{X}_n - m)^2 - 2 \sum_{i=1}^n (X_i - m)(\bar{X}_n - m) \right)$$

$$S_n^2 = \frac{1}{n} \left( \sum_{i=1}^n (X_i - m)^2 + n(\bar{X}_n - m)^2 - 2(\bar{X}_n - m) \sum_{i=1}^n (X_i - m) \right)$$

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n ((X_i - m) - (\bar{X}_n - m))^2$$

$$S_n^2 = \frac{1}{n} \left( \sum_{i=1}^n (X_i - m)^2 + \sum_{i=1}^n (\bar{X}_n - m)^2 - 2 \sum_{i=1}^n (X_i - m)(\bar{X}_n - m) \right)$$

$$S_n^2 = \frac{1}{n} \left( \sum_{i=1}^n (X_i - m)^2 + n(\bar{X}_n - m)^2 - 2(\bar{X}_n - m) \sum_{i=1}^n (X_i - m) \right)$$



$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n ((X_i - m) - (\bar{X}_n - m))^2$$

$$S_n^2 = \frac{1}{n} \left( \sum_{i=1}^n (X_i - m)^2 + \sum_{i=1}^n (\bar{X}_n - m)^2 - 2 \sum_{i=1}^n (X_i - m)(\bar{X}_n - m) \right)$$

$$S_n^2 = \frac{1}{n} \left( \sum_{i=1}^n (X_i - m)^2 + n(\bar{X}_n - m)^2 - 2(\bar{X}_n - m) \sum_{i=1}^n (X_i - m) \right)$$

$$\sum_{i=1}^n (X_i - m) = \sum_{i=1}^n X_i - nm = n(\bar{X}_n - m)$$

Ainsi

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 - (\bar{X}_n - m)^2$$

$$\sum_{i=1}^n (X_i - m) = \sum_{i=1}^n X_i - nm = n(\bar{X}_n - m)$$

Ainsi

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 - (\bar{X}_n - m)^2$$

$$\sum_{i=1}^n (X_i - m) = \sum_{i=1}^n X_i - nm = n(\bar{X}_n - m)$$

Ainsi

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 - (\bar{X}_n - m)^2$$

$$\sum_{i=1}^n (X_i - m) = \sum_{i=1}^n X_i - nm = n(\bar{X}_n - m)$$

Ainsi

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 - (\bar{X}_n - m)^2$$

$$\sum_{i=1}^n (X_i - m) = \sum_{i=1}^n X_i - nm = n(\bar{X}_n - m)$$

Ainsi

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 - (\bar{X}_n - m)^2$$

On a :

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n (X_i - m)^2\right] =$$

et

$$\mathbb{E}[(\bar{X}_n - m)^2] =$$

On a :

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n (X_i - m)^2\right] = \frac{1}{n} \sum_{i=1}^n V(X_i) = s^2$$

et

$$\mathbb{E}[(\bar{X}_n - m)^2] =$$



On a :

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n (X_i - m)^2\right] = \frac{1}{n} \sum_{i=1}^n V(X_i) = s^2$$

et

$$\mathbb{E}[(\bar{X}_n - m)^2] = V(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n V(X_i) = \frac{1}{n} s^2$$

Par conséquent :

$$\mathbb{E}[S_n^2] = s^2 - \frac{s^2}{n}$$

D'où

$$\mathbb{E}[S_n^2] = \frac{n-1}{n} s^2$$

On choisit comme estimation de  $\theta$  la valeur qui maximise la probabilité de provoquer l'apparition de l'échantillon effectivement observé.

### Maximum de vraisemblance

Soit  $x_1, x_2, \dots, x_n$  un échantillon, on note :

$$p = P(x_1, \theta) \dots P(x_n, \theta) = L(x_1, \dots, x_n, \theta)$$

Dans le cas continue,

$$p = f(x_1, \theta) \dots f(x_n, \theta) dx_1 \dots dx_n \text{ où } f \text{ est la densité des VAR}$$

On cherche alors à résoudre :

$$L(x_1, \dots, x_n, \hat{\theta}) = \max_{\theta} L(x_1, \dots, x_n, \theta)$$

En général, on cherche à maximiser  $\ln(L)$

## Propriété

L'estimateur du maximum de vraisemblance du paramètre  $\theta$  est la solution de :

$$\frac{\partial \ln(X, \theta)}{\partial \theta} = 0$$

$$\frac{\partial^2 \ln(X, \theta)}{\partial \theta^2} < 0$$

## Exemple

Soit une population, avec  $X \rightsquigarrow \mathcal{N}(m, \sigma)$ .

On cherche à estimer  $m$  et  $\sigma$

$$L = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-(x_i - m)^2 / (2\sigma^2)}$$

## Propriété

L'estimateur du maximum de vraisemblance du paramètre  $\theta$  est la solution de :

$$\frac{\partial \ln(X, \theta)}{\partial \theta} = 0$$

$$\frac{\partial^2 \ln(X, \theta)}{\partial \theta^2} < 0$$

## Exemple

Soit une population, avec  $X \rightsquigarrow \mathcal{N}(m, \sigma)$ .

On cherche à estimer  $m$  et  $\sigma$

$$L = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-(x_i - m)^2 / (2\sigma^2)}$$

$$L = \frac{1}{(\sqrt{2\pi}\sigma)^n} e^{-\sum (x_i - m)^2 / (2\sigma^2)}$$

$$\ln L = -n \ln(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2$$

$$\ln L = -n \ln(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2$$

$$\frac{\partial L}{\partial m} = 0 \Leftrightarrow \frac{1}{2\sigma^2} \sum_{i=1}^n 2(x_i - m) = 0$$

$$\ln L = -n \ln(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2$$

$$\frac{\partial L}{\partial m} = 0 \Leftrightarrow \frac{1}{2\sigma^2} \sum_{i=1}^n 2(x_i - m) = 0$$

$$\frac{\partial L}{\partial \sigma} = 0 \Leftrightarrow -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - m)^2 = 0$$



## Loi du Khi deux

Soit  $X_1, X_2, \dots, X_n$   $n$  variables aléatoires normales centrées réduites indépendantes.

On pose  $U = \sum_{i=1}^n X_i^2$

On dit que  $U$  suit une loi du Khi deux à  $n$  degrés de liberté, on note  $U \rightsquigarrow \chi_n^2$ .

On a  $E[U] = n$  et  $V(U) = 2n$

## Loi du Student

Soit  $X \rightsquigarrow \mathcal{N}(0, 1)$  et  $Y_n \rightsquigarrow \chi_n^2$

$$\text{Soit } T_n = \frac{X}{\sqrt{Y_n/n}}$$

On dit que  $T_n$  suit une loi du Student à  $n$  degrés de liberté.

## intervalle de confiance

Il est préférable de compléter l'estimation ponctuelle par une fourchette, c'est à dire, nous cherchons  $a$  et  $b$  tel que :

$P(a \leq \theta \leq b) = 1 - \alpha$  où  $\theta$  est la valeur que l'on souhaite estimée (moyenne ou variance)

$1 - \alpha$  est appelé **niveau de confiance** de l'intervalle, on dit aussi que  $[a; b]$  est un intervalle de confiance de  $\theta$  **au risque**  $\alpha$

On cherchera  $a$  et  $b$  tel que  $P(\theta \leq a) = P(\theta \geq b) = \frac{\alpha}{2}$

# intervalle de confiance d'une proportion

Soit  $K_n$  la variable aléatoire qui compte le nombre d'individu ayant la propriété  $P$  dans un échantillon de taille  $n$  non exhaustif.

On a  $K_n \rightsquigarrow \mathcal{B}(n, f)$

Si l'approximation par une loi normale est justifiée  $F_n = \frac{K_n}{n}$  est  
proche d'une loi normale  $F_n \rightsquigarrow \mathcal{N}(f, \sqrt{\frac{f(1-f)}{n}})$

On pose  $U = \frac{F - f}{\sqrt{\frac{f(1-f)}{n}}} \rightsquigarrow \mathcal{N}(0, 1)$ .

On obtient ainsi l'intervalle de confiance au risque  $\alpha$

$$I_{\alpha} = \left[ \hat{f} - \sqrt{\frac{\hat{f}(1 - \hat{f})}{n}} t_{1-\alpha/2}; \hat{f} + \sqrt{\frac{\hat{f}(1 - \hat{f})}{n}} t_{1-\alpha/2} \right]$$

où  $\hat{f}$  est la fréquence de l'échantillon

**Exemple :** 1000 électeurs choisis au hasard ont été interrogés avant une élection. 520 se sont déclarés favorables au candidat A.  
Déterminer un intervalle de confiance à 95% de la proportion  $p$  d'électeurs favorables à A dans la population.

### Exemple :

Soit  $F$  la variable aléatoire égale à la proportion de personnes qui votent pour A. On a

$$F \rightsquigarrow \mathcal{N}\left(0,52, \sqrt{\frac{0,52 \times 0,48}{1000}}\right)$$

On cherche a et b tel que

$$P(a \leq F \leq b) = 0,95$$



**Exemple :** On pose

$$F^* = \frac{F - 0,52}{\sqrt{\frac{0,52 \times 0,48}{1000}}}$$

On cherche  $\alpha$  et  $\beta$  tel que

$$P(\alpha \leq F^* \leq \beta) = 0,95$$

En utilisant la table de la loi normale centrée réduite, on obtient :  $\alpha = -1,96$  et  $\beta = 1,96$

Ainsi l'intervalle de confiance au seuil de 5

$$I = [0,52 - 1,96\sqrt{\frac{0,52 \times 0,48}{1000}}; 0,52 + 1,96\sqrt{\frac{0,52 \times 0,48}{1000}}]$$

$$I = [0,489; 0,551]$$

## intervalle de confiance de la moyenne

**1er cas :  $\sigma$  est connu** Si les variables aléatoires  $X_1, X_2, \dots, X_n$  suivent des lois normales de paramètre  $(m, \sigma)$  ou si  $n > 30$  alors  $\bar{X}_n \rightsquigarrow \mathcal{N}(m, \frac{\sigma}{\sqrt{n}})$  ou  $\bar{X}_n$  tend vers  $Y \rightsquigarrow \mathcal{N}(m, \frac{\sigma}{\sqrt{n}})$ .

## intervalle de confiance de la moyenne

**1er cas :  $\sigma$  est connu** On pose

$$U = \frac{\bar{X}_n - m}{\sigma/\sqrt{n}} \rightsquigarrow \mathcal{N}(0, 1)$$

Ainsi on cherche  $a$  et  $b$  tels que :

$$\begin{cases} \mathbb{P}(\bar{X}_n \leq a) = \alpha/2 \\ P(\bar{X}_n \leq b) = 1 - \frac{\alpha}{2} \end{cases} \Leftrightarrow \begin{cases} \mathbb{P}(U \leq \frac{b-m}{\sigma/\sqrt{n}}) = \alpha/2 \\ P(U \leq \frac{b-m}{\sigma/\sqrt{n}}) = 1 - \frac{\alpha}{2} \end{cases}$$

## intervalle de confiance de la moyenne

**1er cas :  $\sigma$  est connu** On obtient ainsi  $t_{\alpha/2}$  sur la table de la loi normale centrée réduite tel que :

$$\frac{a - m}{\sigma/\sqrt{n}} = t_{\alpha/2}$$

$$\frac{b - m}{\sigma/\sqrt{n}} = t_{1-\alpha/2}$$

On a donc :

$$a = t_{\alpha/2} \frac{\sigma}{\sqrt{n}} + m$$

$$b = t_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} + m$$

1er cas :  $\sigma$  est connu

L'intervalle de confiance de  $m$  au risque  $\alpha$  est :

$$I_{\alpha} = \left[ \hat{m} - \frac{\sigma}{\sqrt{n}} t_{1-\alpha/2}; \hat{m} + \frac{\sigma}{\sqrt{n}} t_{1-\alpha/2} \right]$$

## 2ième cas : $\sigma$ est inconnu

Dans ce cas, on pose  $T = \frac{\bar{X}_n - m}{\sqrt{S_n^2/(n-1)}}$

T suit une loi du Student à  $n-1$  degré de liberté, on utilise la table numérique du Student pour obtenir  $a$  et  $b$  tel que

$$P(a \leq \bar{X}_n \leq b) = 1 - \alpha$$

## 2ième cas : $\sigma$ est inconnu

On a donc

$$P\left(\frac{a - m}{\sqrt{s^2/(n-1)}} \leq \frac{\bar{X}_n - m}{\sqrt{S_n^2/(n-1)}} \leq \frac{b - m}{\sqrt{s^2/(n-1)}}\right) = 1 - \alpha$$

L'intervalle de confiance de  $m$  au risque  $\alpha$  est :

$$I_\alpha = \left[ \hat{m} - \frac{\hat{s}}{\sqrt{n-1}} t_{1-\alpha/2}; \hat{m} + \frac{\hat{s}}{\sqrt{n-1}} t_{1-\alpha/2} \right]$$

**2ième cas :  $\sigma$  est inconnu : Exemple** On réceptionne des pièces et on sait que la longueur des pièces à une distribution normale.

On prélève un échantillon de 20 pièces qui a une moyenne de 10cm et un écart type de 2.

Déterminons un intervalle de confiance de la moyenne de la longueur des pièces au risque de 5



**2ième cas :  $\sigma$  est inconnu :**

### Exemple

Soit  $X_1, X_2, \dots, X_{20}$  les variables aléatoires égales à la longueur des 20 pièces prélevées.

On pose

$$\bar{X}_{20} = \frac{\sum X_i}{20}$$

$$T = \frac{\bar{X}_{20} - m}{\sqrt{S_{20}^2/19}}$$

T suit une loi du Student à 19 ddl.

On cherche a et b tel que

$$P(a \leq \overline{X}_{20} \leq b) = 0,95$$

on obtient

$$P\left(\frac{a - m}{\sqrt{s_{20}^2/19}} \leq T \leq \frac{b - m}{\sqrt{s_{20}^2/19}}\right) = 0,95$$

utilisant la table de la loi du Student, on obtient :

$$\frac{a - m}{\sqrt{s_{20}^2/19}} = -2,093$$

$$\frac{b - m}{\sqrt{s_{20}^2/19}} = 2,093$$

Ainsi l'intervalle de confiance est :

$$I = [10 - 2,093 \times \sqrt{\frac{4}{19}}; 10 + 2,093 \times \sqrt{\frac{4}{19}}]$$

$$I = [9,0397; 10,9603]$$

Soit  $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

On pose :

$$Y = (n-1) \frac{S_n^2}{\sigma^2}$$

$Y$  suit une loi du Khi deux à  $(n-1)$  degrés de liberté.

On détermine  $a$  et  $b$  dans la table du Khi deux tel que :

$$P(a \leq (n-1) \frac{S_n^2}{\sigma^2} \leq b) = 1 - \alpha$$

On obtient ainsi l'intervalle de confiance de la variance :

$$I_{\alpha} = \left[ \frac{(n-1)\hat{s}^2}{b}; \frac{(n-1)\hat{s}^2}{a} \right]$$

**Exemple :** On a un échantillon de 16 chiffres d'affaires tel que  $s_{16} = 72,53$ .  
Déterminer l'intervalle de confiance de la variance de niveau 0,95.