# Quelques precisions sur les instructions et la compilation

- Format des Instructions et focus sur J/JAL
- Multiplication et Division
- Interpretation vs. Translation
- De l'assembleur à l'exécution

Credits UC Berkley's CS61C.

#### Format des instructions: RISC-V

| 31         | 30  | 25      | 24 2         | 1   | 20      | 19     | 15    | 14          | <b>12</b> | 11 8         | 7         | 6    | 0      |        |
|------------|---|---------|--------------|-----|---------|--------|-------|-------------|-----------|--------------|-----------|------|--------|--------|
|            | funct7  |         | 1            | s 2 |         | rs     | 1     | funct3      |           | ro           | d         | opco | ode    | R-type |
| rd = rs1 O | rd = rs1 OP rs2   |         |              |     |         |        |       |             |           |              |           |      |        |        |
|            | in  | nm[11   | 1:0]         |     |         | rs     | 1     | funct3      |           | ro           | d         | opco | ode    | I-type |
| rd = rs1 O | rd = rs1 OP Immediate; Load rd from Memory(rs1 + Immediate); JALR (rd = PC + 4, PC = rs1 + Immediate) |         |              |     |         |        |       |             |           |              |           |      |        |        |
| im         | m[11:5]   |         | 1            | s 2 |         | rs     | 1     | funct3      |           | imm          | [4:0]     | opco | ode    | S-type |
| Store rs2  | Store rs2 to Memory(rs1 + Immediate)  |         |              |     |         |        |       |             |           |              |           |      |        |        |
| imm[12]    | imm[1   | 0.05    | 1            | s2  |         | rs     | 1     | funct3      |           | imm[4:1]     | imm[11]   | opco | ode    | B-type |
| Branch if  | (rs1 condit   | tion rs | 2) is true t | o M | emory(F | C + Im | media | te*2), i.e. | ., F      | PC = PC + Im | mediate*2 |      |        |        |
|            | $\operatorname{imm}[31:12]$   |         |              |     |         |        |       |             | rd        |              | opco      | ode  | U-type |        |
| Upper "Lo  | Upper "Long" Immediate (AUIPC, LUI): PC or rd = {imm, 12b'0}  |         |              |     |         |        |       |             |           |              |           |      |        |        |
| imm[20]    | in  | nm[10]  | ):1]         | im  | m[11]   | i      | mm[1] | 9:12]       |           | ro           | d         | opco | ode    | J-type |
| JAL to Me  | JAL to Memory (PC + Immediate*2), i.e., rd = PC + 4; PC = PC + immediate*2                            |         |              |     |         |        |       |             |           |              |           |      |        |        |

Credits UC Berkley's CS61C.

## J-Format pour les instruction Jump (JAL)

|   | 31      | 30 |           | 21   | 20      | 19 1       | 2 11                  | 7 6                  | 0 |
|---|---------|----|-----------|------|---------|------------|-----------------------|----------------------|---|
|   | imm[20] |    | imm[10:1] |      | imm[11] | imm[19:12] | rd                    | opcode               |   |
| ٠ | 1       |    | 10        |      | 1       | 8          | 5                     | 7                    |   |
|   |         |    | offset[   | 20:1 | .]      |            | $\operatorname{dest}$ | $\operatorname{JAL}$ |   |

- JAL sauvegarde PC+4 dans le register rd (adresse de retour)
  - L'instruction assembleur "j" jump est une pseudo-instruction, utilise
     JAL mais place rd=x0 pour ignorer l'adresse de retour.
- Met à jour la valeur du PC = PC + offset

# Utilisations de JAL

```
# j pseudo-instruction
j Label = jal x0, Label # l'adresse de retour est
ignorée
```

# Appel d'une fonction dans un espace de 2<sup>18</sup> instructions autour du PC jal ra, FuncName

#### Instruction JALR (I-Format)

| 31                   | 20 19 | 15 14 12 | 11 7                  | 6                     | 0 |
|----------------------|-------|----------|-----------------------|-----------------------|---|
| $\mathrm{imm}[11:0]$ | rs1   | funct3   | rd                    | opcode                |   |
| 12                   | 5     | 3        | 5                     | 7                     |   |
| offset[11:0]         | base  | 0        | $\operatorname{dest}$ | $\operatorname{JALR}$ |   |

- JALR rd, rs, immediate
  - Sauvegarde PC+4 dans rd (adresse de retour)
  - Fixe le PC = rs + immediate (12 bit)

#### Utilisation de JALR

```
# ret et jr pseudo-instructions
ret = jr ra = jalr x0, ra, 0

# Appel de fonction à n'importe quelle adresse de 32
bits
lui x1, <hi20bits>
jalr ra, x1, <lo12bits>

# Saut "PC-relative" avec un offset de 32 bits
auipc x1, <hi20bits>
jalr x0, x1, <lo12bits>
```

#### **Pseudo Instructions**

| MNEMONIC       | NAME           | DESCRIPTION                             | USES   |
|----------------|----------------|---|--------|
| beqz           | Branch = zero  | $if(R[rs1]==0) PC=PC+\{imm,1b'0\}$      | beq    |
| bnez           | Branch ≠ zero  | if(R[rs1]!=0) PC=PC+{imm,1b'0}          | bne    |
| fabs.s,fabs.d  | Absolute Value | F[rd] = (F[rs1] < 0) ? -F[rs1] : F[rs1] | fsgnx  |
| fmv.s,fmv.d    | FP Move        | F[rd] = F[rs1]                          | fsgnj  |
| fneg.s, fneg.d | FP negate      | F[rd] = -F[rs1]                         | fsgnjn |
| j              | Jump           | $PC = \{imm, 1b'0\}$                    | jal    |
| jr             | Jump register  | PC = R[rs1]                             | jalr   |
| la             | Load address   | R[rd] = address                         | auipc  |
| li             | Load imm       | R[rd] = imm                             | addi   |
| mv             | Move           | R[rd] = R[rs1]                          | addi   |
| neg            | Negate         | R[rd] = -R[rs1]                         | sub    |
| nop            | No operation   | R[0] = R[0]                             | addi   |
| not            | Not            | $R[rd] = \sim R[rs1]$                   | xori   |
| ret            | Return         | PC = R[1]                               | jalr   |
| seqz           | Set = zero     | R[rd] = (R[rs1] == 0) ? 1 : 0           | sltiu  |
| snez           | Set ≠ zero     | R[rd] = (R[rs1]! = 0) ? 1 : 0           | sltu   |

Instructions valides en assembleur mais non en langage machine (i.e., plusieurs instructions en langage machine sont nécessaires pour les exécuter)

# Quelques precisions sur les instructions et la compilation

- Format des Instructions et focus sur J/JAL
- Multiplication et Division
- Interpretation vs. Translation
- De l'assembleur à l'exécution

### Multiplication d'entier (1/3)

• Un exemple (unsigned):

• m bits x n bits = produit de m + n bits

### Multiplication d'entier (2/3)

- Dans l'architecture RISC-V, on multiplie le contenu des registres:
  - Valeur de 32bits value x valeur de 32bits = valeur de 64 bits
- Syntaxe de la Multiplication (signed):
  - MUL réalise une multiplication 32-bit×32-bit et sauvegarde les 32 bits de poids faible du résultat dans le registre de destination
  - MULH réalise une multiplication 32-bit×32-bit et sauvegarde les 32 bits de poids fort du résultat dans le registre de destination

# Multiplication d'entier (3/3)

#### • Exemple:

```
- En C: a = b * c; # a doit être declaré comme un
long long
```

- En assembleur RISC-V:
  - B dans t2, c dans t3 et a dans t0 et t1

```
# upper half of
# product into $s0
# lower half of
# product into $s1
```

11

## Multiplication d'entier (3/3)

#### • Exemple:

```
- En C: a = b * c; # a doit être declaré comme un
long long
- En assembleur RISC-V:
```

• B dans t2, c dans t3 et a dans t0 et t1

#### Multiplication d'entier (3/3)

- Exemple:
  - En C: a = b \* c; # a doit être declaré comme un long long
  - En assembleur RISC-V:
    - B dans t2, c dans t3 et a dans t0 et t1

13

#### Division d'entier

- Syntaxe de la Division (signed):
  - DIV realise une division d'un entire de 32 bits par un entire de 32 bits, REM donne le reste de la division.

```
DIV rdq, rs1, rs2
REM rdr, rs1, rs2
```

- Implementation en C de la division division (/) et du modulo (%)
- C: a = c / d; b = c % d;
- Assembleur RISC-V: a↔t0; b↔t1; c↔t2; d↔t3

  div t0,t2,t3 # a=c/d

  rem t1,t2,t3 # b=c%d

#### Question

Parmi les propositions ci dessous, quelle(s) séquence(s) charge(nt) l'adresse de LOOP dans T1?

- 1) la t2, LOOP
   lw t1, 0(t2)
- jal LOOP
  LOOP: add t1, ra, x0
- 3) la t1, LOOP

# Question


Parmi les propositions ci dessous, quelle(s) sequence(s) charge(nt) l'adresse de LOOP dans T1?

- 1) la t2, LOOP
   lw t1, 0(t2)
- jal LOOP LOOP: add t1, ra, x0
- 3) la t1, LOOP

# Quelques precisions sur les instructions et la compilation

- Format des Instructions et focus sur J/JAL
- Multiplication et Division
- Interpretation vs. Translation
- De l'assembleur à l'exécution

#### Levels of Representation/Interpretation




#### Interprétation vs Compilation

- Un Interpreteur est un programme qui exécute un autre programme:
  - L'interprétation du code source est un processus « pas à pas » : l'interpréteur va exécuter les lignes du code une par une, en décidant à chaque étape ce qu'il va faire ensuite.
- Dans un langage interprété, le même code source pourra marcher directement sur tout ordinateur. Avec un langage compilé, il faudra (en général) tout recompiler à chaque fois ce qui pose parfois des soucis.
- Dans un langage compilé, le programme est directement exécuté sur l'ordinateur, donc il sera en général plus rapide que le même programme dans un langage interprété.

#### Interpretation

• Par exemple, considérons un programme en python foo.py



• L'interpéteur Python est simplement un programme qui lit le python et exécute les fonctionnalités de ce programme.

#### Interpretation vs. compilation? (1/2)


- C'est généralement plus simple d'ecrire un interpréteur
- L'interpréteur est plus proche du langage haut niveau et peut donc donner plus d'informations de debuggig
- L'interpréteur est plus lent (10x?), le code plus petit(2x?)
- L'interpréteur rend le code à executer independent du jeu d'instruction

2:

#### Interpretation vs. compilation? (2/2)

- Le code compilé est plus efficace:
  - Important pour beaucoup d'applications
- La compilation aide à garder secret le code source du programme à l'utilisateur

### Les étapes pour compiler un code C




Credits UC Berkley's CS61C.

2

#### Compilateur

- Entrée: code langage de haut niveau(e.g., foo.c)
- Sortie: code assembleur
   (e.g., foo.s pour RISC-V)
- Note: La sortie peut contenir des pseudo instructions
- <u>Pseudo-instructions</u>: instructions que l'assembleur comprend mais pas présente dans l'architecture
  - Par exemple (move t2 to t1):
  - -mv t1,t2  $\Rightarrow$  addi t1,t2,0

## Du programme à l'exécution



25

#### **Assembleur**

- Entrée: langage assembleur (e.g., foo.s pour RISC-V)
- Sortie: Code objet pur assembleur seulement)
   (e.g., foo.o pour RISC-V)
- Lits et utilises des Directives
- Remplace les Pseudo-instructions
- Produit le langage Machine
- Crée le fichier objet

#### Directives assembleur

• Donne des directives à l'assembleur mais ne produit pas d'instructions machines

.text: Subsequent items put in user text segment (machine

code)

Subsequent items put in user data segment (binary rep of .data:

data in source file)

declares sym global and can be referenced from other .globl sym:

Store the string **str** in memory and null-terminate it .string str: .word w1...wn:

Store the *n* 32-bit quantities in successive memory

words

#### Remplacement des Pseudo-instructions

```
Pseudo:
                      Real:
mv t0, t1
                      addi t0,t1,0
                      sub t0, zero, t1
neg t0, t1
li tO, imm
                      addi t0, zero, imm
                      xori t0, t1, -1
not t0, t1
begz t0, loop
                      beq t0, zero, loop
la t0, str
                      lui t0, str[31:12]
                      addi t0, t0, str[11:0] ou
                      auipc t0, str[31:12]
                      addi t0, t0, str[11:0]
```

### Génération du langage machine (1/3)

- Cas simple
  - Opérations arithmétiques et logiques
  - Toutes les infos sont connues dans l'instruction
- Branchements et sauts?
  - PC-Relative (e.g., **beq/bne** and **jal**)
  - Lorsque les pseudo instructions sont remplacées par les instructions réelles, on sait de combien d'instructions on doit "sauter"

29

#### Génération du langage machine(2/3)

- Le problème des "Forward Reference"
  - Une instruction de branchement peut faire reference à des labels qui sont plus loin dans le programme

```
2 words forward

3 words forward

2 words back

3 words back

3 words back

L1 addi t2, zero, 9 # t2 = 9

# 0 >= t2? Exit!

# 0 < t2; t2--

# Go to L1
```

- C'est résolu en faisant deux passes sur le programme
  - · La première passe mémorise les positons des labels
  - La seconde utilise la position des labels pour générer le code

#### Génération du langage machine(3/3)

- Comment gérer les sauts ou branchements avec des déplacements par rapport au PC (PC-relative jumps (jal) and branches (beq, bne))?
  - j offset pseudo instruction qui correspond à JAL zero, offset
  - On compte simplement le nombre d'instructions entre la cible et le saut pour déterminer l'offset (à donner en demi mots), on parle de code indépendant de la position : position-independent code (PIC)
- Que se passe-t-il si on fait référence à des données statiques?
  - la correspond aux instructions lui et addi
  - Cela nécessite de connaître l'adresse complète sur 32 bits
- Cela ne peut donc pas être connu à cet instant, on crée donc une table

10/25/20 Fall 2017 - Lecture #8 31

#### Table des Symboles

- La **table des symboles** est une **table** qui indique à un instant donné à quoi correspondent les identificateurs
- Que sont les identificateurs?
  - Labels: appel de fonctions
  - Data: les éléments stockés dans la section.data

#### **Relocation Table**

- List of "items" whose address this file needs What are they?
  - Any absolute label jumped to: jal, jalr
    - Internal
    - External (including lib files)
    - Such as the la instruction
       E.g., for jalr base register
  - Any piece of data in static section
    - Such as the la instruction
       E.g., for lw/sw base register

33

#### **Object File Format**


- object file header: size and position of the other pieces of the object file
- <u>text segment</u>: the machine code
- data segment: binary representation of the static data in the source file
- <u>relocation information</u>: identifies lines of code that need to be fixed up later
- <u>symbol table</u>: list of this file's labels and static data that can be referenced
- debugging information
- A standard format is ELF (except MS)
   http://www.skyfree.org/linux/references/ELF\_Format.pdf

# Quelques precisions sur les instructions et la compilation

- Format des Instructions et focus sur J/JAL
- Multiplication et Division
- Interpretation vs. Translation
- De l'assembleur à l'exécution

0.5

# Du programme à l'exécution



10/25/20 Fall 2017 - Lecture #8 36

#### Linker (1/3)

- Entrées: fichiers code objet, tables d'informations(e.g., foo.o,libc.o for RISC-V)
- sortie: code Exécutable (e.g., a out for RISC-V)
- Combine plusieurs fichiers objet(.o) pour former un seul exécutable("<u>linking</u>")
- Cela permet la compilation séparée
  - Le changement d'un fichier ne nécessite pas de tout recompiler
    - Sources de Linux > 20 M lignes of code!

37

# Linker (2/3) .o file 1 text 1 data 1 info 1 Linker .o file 2 text 2 data 2 info 2 Linker Relocated text 1 Relocated data 1 Relocated data 2

### Linker (3/3)

- 1. Extraction de chaque segment .text des fichiers .o file pour les réunir dans un seul
- 2. Extraction de chaque segment .data segment des fichiers . o pour les réunir dans un seul et les concaténer au segment.text créé précédemment
- 3. Résolution des références
  - Accès à chaque table pour résoudre les références.

39

#### 4 Types d'adresse

- PC-Relative Addressing (beq, bne, jal; auipc/addi)
  - Pas besoin de resolution(PIC: position independent code)
- Absolute Function Address (auipc/jalr)
  - Besoin de résolution
- External Function Reference (auipc/jalr)
  - Besoin de résolution
- Static Data Reference (often lui/addi)
  - Besoin de résolution

#### Adressage absolu RISC-V

- Quelles instructions nécessitent de résoudre les adresses?
  - J-format: jump/jump and link

| xxxxx | rd | jal |
|-------|----|-----|
|-------|----|-----|

- I-,S- Format: Loads and stores to variables in static area, relative to global pointer

| xxx |     | gp | rd | lw |
|-----|-----|----|----|----|
| xx  | rs1 | gp | x  | sw |

- What about conditional branches?

| xx | rs1 | rs2 | x | beq |
|----|-----|-----|---|-----|
|    |     |     |   | bne |

- PC-relative addressing preserved even if code moves

4

#### Résolution des références (1/2)


- Le Linker considére que le 1er mot du 1er segment text est à 0x10000.
- Le Linker connait:
  - La longueur de chaque segment text et data
  - L'ordre des segments
- Le linker calcule :
  - Les addresses absolues de chaque label et des données qui sont référencées

# Résolution des références (2/2)

- Pour résoudre les références:
  - Recherche des références dans les tables des symboles
  - Si non présent recherche dans les fichiers de librairies(e.g., pour printf)
  - Lorsque l'adresse absolue est déterminée, le code machine est complété
- Le linker génère le fichier exécutable

. .

# Du programme à l'execution



#### Le Loader

- Entrée: Code exécutable (e.g., a.out for RISC-V)
- Sortie: Le programme s'exécute
- Les fichiers exécutables sont stockés dans le disque
- Lorsqu'un exécutable est lancée, le job du loader est de le charger en mémoire et de le lancer.
- Dans les systèmes, le loader est le système d'exploitation (OS)
  - C'est une des taches de l'OS

45

## Le loader ... Qu'est ce qu'il fait?

- Lit l'entête de l'exécutable pour déterminer la taille des segments text et data.
- Crée un nouvel espace d'adressage suffisamment grand pour le programme pour stocker les segments de pile, data et text
- Copie les instructions et les données depuis le fichier exécutable dans l'espace d'adressage alloué.
- Copie les arguments passés au programme dans la pile
- Initialise les registres
- Saute à la routine de démarrage qui copie les arguments de la pile vers les registres et place la valeur du PC

#### Compiled Hello.c: Hello.s

```
.text
                                                 # Directive: enter text section
 .align 2
                                                 # Directive: align code to 2^2 bytes
  .globl main
                                                 # Directive: declare global symbol main
main:
                                                 # label for start of main
 addi sp,sp,-16
                                                 # allocate stack frame
 sw ra, 12(sp)
                                                 # save return address
 lui a0,%hi(string1)
                                                 # compute address of
 addi a0,a0,%lo(string1)
                                                    string1
 lui a1,%hi(string2)
                                                 # compute address of
 addi a1,a1,%lo(string2)
                                                    string2
 call printf
                                                 # call function printf
      ra,12(sp)
                                                 # restore return address
 addi sp, sp, 16
                                                 # deallocate stack frame
                                                 # load return value 0
 li a0,0
 .section .rodata
                                                 # Directive: enter read-only data section
  .balign 4
                                                 # Directive: align data section to 4 bytes
string1:
                                                 # label for first string
 .string "Hello, %s!\n"
                                                 # Directive: null-terminated string
string2:
                                                 # label for second string
 .string "world"
                                                 # Directive: null-terminated string
```

477

#### Assembled Hello.s: Linkable Hello.o

```
00000000 <main>:
    ff010113 addi sp,sp,-16
    00112623 sw ra, 12(sp)
    00000537 lui a0,0x0
                              # addr placeholder
    00050513 addi a0,a0,0
                             # addr placeholder
10: 000005b7 lui a1,0x0
                              # addr placeholder
14: 00058593 addi a1,a1,0
                             # addr placeholder
18: 00000097 auipc ra,0x0
                              # addr placeholder
1c: 000080e7 jalr ra
                              # addr placeholder
20: 00c12083 lw ra,12(sp)
24: 01010113 addi sp,sp,16
28: 00000513 addi a0,a0,0
2c: 00008067 jalr ra
```

#### Linked Hello.o: a.out

```
000101b0 <main>:
    101b0: ff010113 addi sp,sp,-16
    101b4: 00112623 sw ra,12(sp)
    101b8: 00021537 lui a0,0x21
    101bc: a1050513 addi a0,a0,-1520 # 20a10 <string1>
    101c0: 000215b7 lui a1,0x21
    101c4: a1c58593 addi a1,a1,-1508 # 20a1c <string2>
    101c8: 288000ef jal ra,10450 # <pri>printf>
    101cc: 00c12083 lw ra,12(sp)
    101d0: 01010113 addi sp,sp,16
    101d4: 00000513 addi a0,0,0
    101d8: 00008067 jalr ra
```

49

# Quelques precisions sur les instructions et la compilation

- Format des Instructions et focus sur J/JAL
- Multiplication et Division
- Interpretation vs. Translation
- De l'assembleur à l'exécution

#### En conclusion, ...

- Le compilateur convertit un fichier en langage de haut niveau en un fichier assembleur
- L'assemblage supprime les pseudo instructions pour les convertir tout ce qui est possible en langage machine et crée les tables pour le linker
  - 2 passes sont nécessaires pour résoudre les adresses
- Le Linker assemble plusieurs fichiers .o et résout les adresses.
  - Cela permet la compilation séparée et résout les derniers problèmes d'adressage
- Le Loader charge l'exécutable en mémoire et débute l'exécution

